



Taller: Análisis de Datos con PySpark

Profesor: Heberth Martinez

Este taller tiene como objetivo que te familiarices con **PySpark** para el procesamiento distribuido de datos utilizando un conjunto de datos real de Salarios.

Objetivo del ejercicio

Dado un archivo CSV con registros de Salarios, debes:

1. Leer los datos usando **pandas** y **pyspark**, comparando los tiempos de carga.
 2. Realizar transformaciones y filtros sobre los datos con PySpark.
 3. Calcular estadísticas básicas como promedio, máximo y mínimo de salarios.
 4. (Opcional) Visualizar los resultados o comparar el rendimiento.
-

Dataset

Usaremos un CSV público con datos de ejemplo:

- [Salary Dataset \(~4MB\)](#)

Guarda el archivo como `data.csv` en el mismo directorio que tu script.

Requisitos técnicos

Opción A: Instalación local

1. Instala Java

- [Descargar Java JDK 11+ \(sitio oficial\)](#)
- En macOS (con Homebrew):

```
brew install openjdk@11
```

2. Crea un entorno virtual e instala dependencias

```
python3 -m venv venv  
source venv/bin/activate  
pip install pyspark pandas
```

Opción B: Usar Docker

1. Crea el archivo `Dockerfile`

```
FROM openjdk:11  
  
RUN apt-get update && apt-get install -y python3 python3-pip  
RUN pip3 install pyspark pandas  
  
WORKDIR /app  
COPY . /app  
  
CMD ["python3", "main.py"]
```

2. Construye y ejecuta el contenedor

```
docker build -t pyspark-app .  
docker run --rm -v $(pwd):/app pyspark-app
```

Estructura del proyecto

```
taller-pyspark/  
|  
├─ main.py           # Script principal a completar  
├─ data.csv          # Dataset descargado  
└─ Dockerfile        # (opcional) Para correr el proyecto en Docker
```

Entregables

1. `main.py` completo con:
 - Lectura con `pandas` y `pyspark`
 - Medición de tiempos
 - Filtros y agregaciones
2. Captura o salida con los tiempos de ejecución
3. Conclusión comparando ambos enfoques
4. (Opcional) Gráfico o tabla con alguna métrica relevante

Recursos útiles

- [PySpark API Docs](#)
- [Documentación de pandas](#)
- [Guía oficial de instalación de Java](#)